「BDA 11 기 학회원 최종 과제」 분석 보고서

과 제 명	조별활동 이탈 방지를 위한 조편성 아이디어 및 전략 제시	성 명	조문영
활용데이터	▪ 학회원 정보 데이터 (member.csv) ▪ 조별활동 정보 데이터 (group_study.csv) ▪ 조별활동 점수 데이터 (group_point.csv)		

1. 주제 선정 및 분석 배경

1.1. 분석 주제: 데이터 기반 조별활동 이탈 요인 분석 및 유지 전략 수립

본 분석은 BDA 학회원 조별활동 데이터(member.csv, group_study.csv, group_point.csv)를 활용하여, 조별활동 참여 중 이탈에 영향을 미치는 핵심 요인을 규명하고 운영 관점에서 적용 가능한 유지 전략을 제안하는 것을 목적으로 한다.

1.2. 분석 배경 및 필요성

조별활동은 개인 학습만으로 얻기 어려운 협업 경험을 제공하고, 정기적인 상호 피드백과 일정 공유를 통해 학습 지속성을 높인다. 또, 구성원 간 친밀도와 상호 책임을 형성해 참여 동기를 유지하는 기반이 된다. 따라서 조별활동은 프로그램 운영 성과를 좌우하는 핵심 활동 형태로, 참여 경험의 질과 지속성을 함께 관리할 필요가 있다.

BDA 학회의 조별활동 과정에서 중도 이탈하는 인원이 지속적으로 발생하고 있으며, 본 분석 데이터 기준 조별활동 참여자 3,473 명 중 510 명**(약 14.7%)**이 이탈한 것으로 확인된다. 학회 활동의 효율성을 높이고 참여도를 끌어올리기 위해서는 어떤 요인이 이탈에 유의미한 영향을 미치는지 데이터 기반으로 파악할 필요가 있다.

본 분석은 단순 이탈률 비교를 넘어, 로지스틱 회귀를 통해 변수별 오즈비(Odds Ratio, 이하 OR)를 산출한다. 오즈비는 해당 변수가 1 단위 증가하거나 특정 조건에 속할 때 이탈 확률이 몇 배로 변화하는지를 나타내므로, 조편성 및 운영 개입 지점을 도출하는 근거로 활용할 수 있다.

1.3. 분석 목표

본 분석의 목표는 다음과 같다.

1) 이탈과 유의미한 관련이 있는 요인을 확인한다.

2) 로지스틱 회귀를 통해 오즈비와 p-value 를 산출하여 이탈 위험 요인을 정량화한다.

3) 군집분석을 통해 학회원 유형을 분류하고, 유형별 이탈률 차이를 비교한다.

4) 분석 결과를 바탕으로 조별활동 이탈 방지 목적의 조편성 및 운영 개선안을 제시한다.

1.4. 가설 설정

본 분석의 초기 가설은 다음과 같다.

[가설 1] 직업(job): 대학생, 대학원생, 직장인 순으로 이탈률이 낮을 것이다.

[가설 2] 재참여 여부(before_id): 이전 기수에 참여한 경험이 있는 학회원은 이탈률이 낮을 것이다.

[가설 3] 활동 방식(on_offline): 오프라인 활동을 선택한 학회원이 온라인보다 이탈률이 낮을 것이다.

[가설 4] 조장 역할(group_master): 조장을 맡은 학회원이 일반 조원보다 이탈률이 낮을 것이다.

[가설 5] 활동 점수(point): 활동 점수가 높은 조일수록 이탈률이 낮을 것이다.

2. 분석 결과 상세 내용

2.1. 데이터 개요

활용 데이터: member.csv, group_study.csv, group_point.csv

분석 단위: 개인(학회원) 단위 기반으로 조별활동 이탈 여부를 종속변수로 구성

2.2. 전처리 및 변수 정의

2.2.1. 데이터 병합 및 정제

1) 데이터 병합을 위해 조인 키(member_id, generation, class_code, group_number 등)의 데이터 타입을 통일하고, 세 데이터를 순차적으로 **Left Join** 하여 분석용 테이블(merged_data.csv)을 구성하였다.

2) 분석에 필요한 플래그 변수를 **0/1 형태**로 변환하였다.

3) **Melt 함수**를 활용해 class1~class4 로 존재하던 값을 세로(long format)로 변환하여 분석의 일관성을 확보하였다.

2.2.2. 결측 처리

모델 입력 변수와 종속변수를 기준으로 결측이 포함된 행은 제거하여 학습 데이터를 구성하였다.

2.2.3. 주요 변수

종속 변수: **leave_flag(이탈 여부, 0/1)**

개인 특성: IT 전공 여부, 직업(job), 재참여 여부(before_id 존재 여부)

활동/운영: 활동 방식(on_offline), 기수(generation), 활동월차(nth_month)

역할/성과: 조장 여부(group_master), 우수조 여부(excellent_group), 활동 점수(point)

2.2.4. 변수 간의 다중공선성 확인

로지스틱 회귀 해석의 안정성을 위해 VIF(다중공선성) 지수를 산출하여 변수 간 중복 정보를 점검하였다. VIF 10 이상을 다중공선성 위험 기준으로 두었다. "온라인" 변수가 VIF 가 11.5 가 나왔으며, 이는 온라인과 오프라인 더미가 서로 같은 정보를 담고 있다고 판단되어 온라인 변수를 제외한 후 진행하였다. 또한, 변수 간 효과 차이를 확인하기 위해 교호작용항을 추가 생성하여 함께 검토하였다.

=== [VIF (다중공선성) 지수 확인] ===
VIF가 10 이상이면 다른 변수와 특성이 너무 겹친다는 뜻입니다.

	변수	VIF
3	온라인	11.547241
9	오프라인	6.875180
10	온라인_x_대학생	5.609658
6	대학생	2.665003
1	기수	2.116045
12	재참여_x_온라인	1.773605
5	재참여	1.624092
7	활동점수	1.282045
4	IT전공	1.270893
8	활동월차	1.130851
11	조장_x_직장인	1.062486
2	조장여부	1.022779

그림 1 온라인 변수 제거 전

=== [VIF (다중공선성) 지수 확인] ===
VIF가 10 이상이면 다른 변수와 특성이 너무 겹친다는 뜻입니다.

	변수	VIF
9	온라인_x_대학생	5.591006
3	온라인	5.316449
6	대학생	2.661308
1	기수	2.109853
11	재참여_x_온라인	1.771551
5	재참여	1.618101
7	활동점수	1.270385
4	IT전공	1.269665
8	활동월차	1.129080
10	조장_x_직장인	1.062337
2	조장여부	1.019540

그림 2 온라인 변수 제거 후

2.2.5. 중요도 기반 변수 필터링

변수 수를 축소하고 핵심 요인을 선별하기 위해 RandomForest 와 XGBoost 에서 산출된 중요도를 비교하여

상위 변수를 선정하였다. 두 모델의 중요도를 종합해 상위 7 개 변수(활동점수, 기수, 조장여부, 재참여, 재참여 x 온라인, 온라인, IT 전공)를 변수로 사용하였다.

2.3. 분석 절차 및 방법론

1) **탐색적 데이터 분석:** 가설 변수별 이탈률을 비교하는 시각화를 수행하였다.

2) **로지스틱 회귀 기반 오즈비 산출 및 검정:** 변수별 **계수, p-value, 오즈비**를 계산하여 변수별 이탈 위험 요인을 정량화하였다.

OR > 1	이탈 확률 증가 (이탈 위험 요인)
OR < 1	이탈 확률 감소 (이탈 방어 요인)
OR = 1	차이 없음

3) **군집분석:** 표준화된 입력 변수를 기반으로 **KMeans 군집(k=3)**을 수행하였다. 군집별 평균 특성과 군집별 이탈률을 비교하여 학회원 유형을 저/중/고위험 군으로 구분하였다.

2.4. 가설 검정

본 보고서에서 가설 검정은 두 단계로 수행하였다.

EDA 기반 1 차 검정: 가설 변수별 이탈률 차이를 시각화하여 방향성을 확인하였다.

Logit 기반 2 차 검정: 로지스틱 회귀의 p-value(유의수준 0.05)를 기준으로 통계적 유의성을 판단하고, 오즈비를 통해 영향의 방향과 크기를 해석하였다.

2.4.1. 가설별 EDA 기반 1 차 검정

1. **[가설 1 검증]** 대학생이 가장 이탈률이 낮을 것이다. -> **기각**

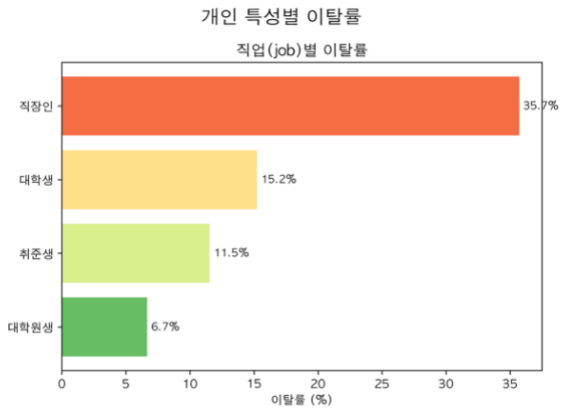

직업별 이탈률은 직장인 35.7%, 대학생 15.2%, 취준생 11.5%, 대학원생 6.7%로 대학생이 직장인 대비 이탈이 낮아 "직업에 따라 이탈이 달라진다"는 가설은 지지되나, 대학생이 최저 이탈 집단은 아니었다. 대학생은 학기 중 시험 기간, 과제, 동아리 등 일정 변수가 커서 시간 여유가 상대적으로 많지 않다고 판단된다.

2. **[가설 2 검증]** 재참여 학회원은 이탈률이 낮을 것이다.-> **채택**

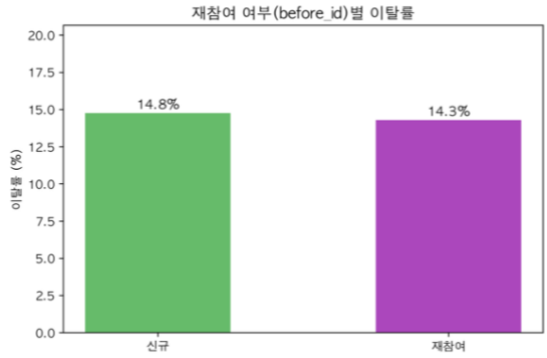

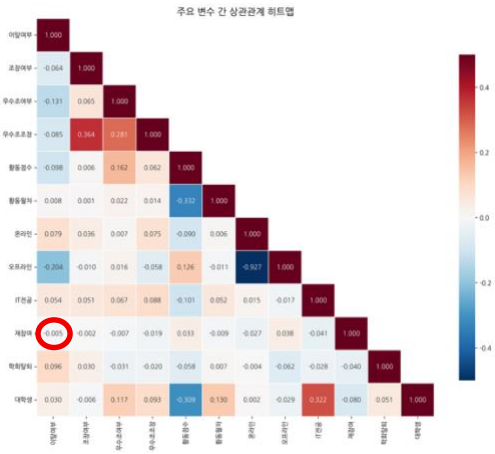

재참여 학회원들의 이탈이 14.3%, 신규 학회원이 14.8%로 신규 학회원의 이탈률이 더 낮지만, 차이는 0.5%p 로 작다. 이는 히트맵에서도 상관계수가 -0.005 로 0 에 수렴하는 것을 알 수 있다.

3. **[가설 3 검증]** 오프라인으로 활동한 학회원이 온라인보다 이탈률이 낮을 것이다. **-> 채택**

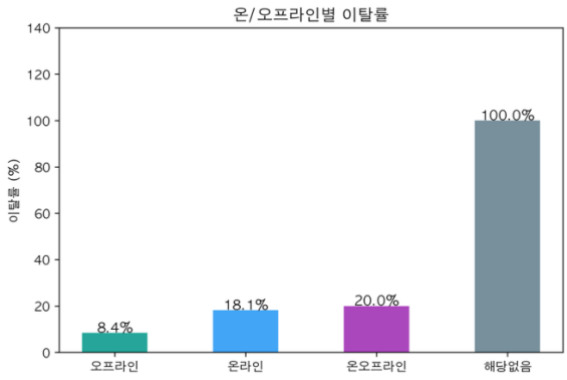

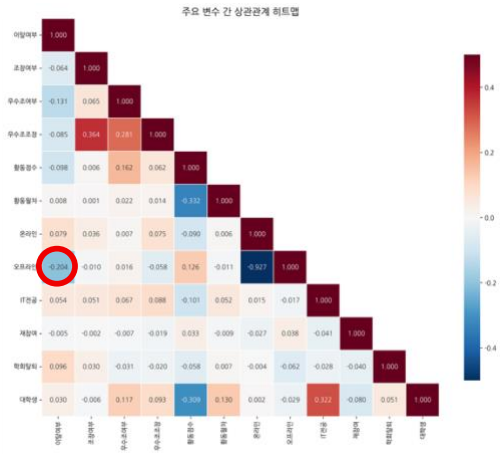

오프라인 이탈률 8.4%가 온라인 18.1% 및 온오프라인 20% 대비 낮게 나타났다. 오프라인 활동은 일정이 고정되고, 조원간의 친밀도가 온라인 대비 높다고 판단된다.

4. **[가설 4 검증]** 조장을 맡은 학회원이 일반 조원보다 이탈률이 낮을 것이다. -> **채택**

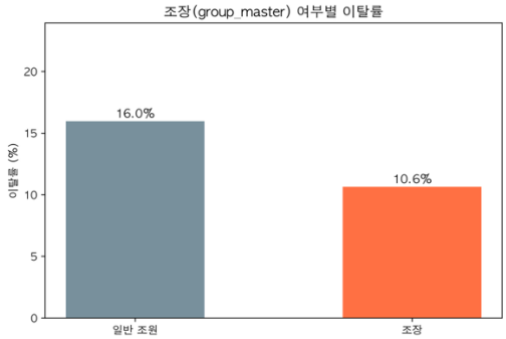

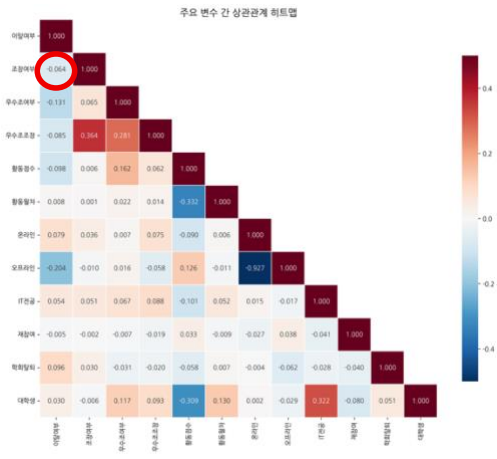

조장의 이탈률 10.6%가 일반 조원 16%보다 낮은 걸로 보아, 조장은 역할 책임과 일정 관리 부담이 존재해 참여 지속성이 높은 걸로 판단된다.

5. **[가설 5 검증]** 활동 점수가 높은 조일수록 이탈률이 낮을 것이다. -> **채택**

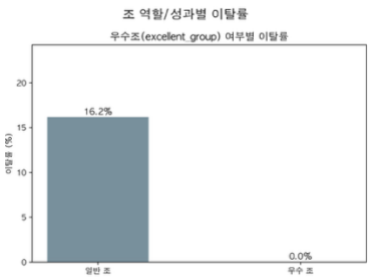

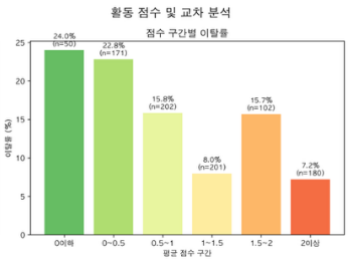

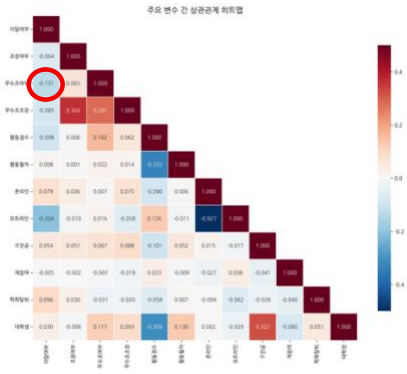

전반적으로 점수가 높을수록 이탈이 감소하는 경향이 확인되었다. 활동 점수는 참여량의 대리변수로

작동할 가능성이 높고, 초기 참여도가 확보된 구성원일수록 이후 이탈 가능성이 낮아지는 구조로 판단된다.

2.4.2 가설별 로지스틱 회귀 기반 2 차 검정

```
=== [통계적으로 유의미한 이탈 영향 요인 (p-value < 0.05)] ===
```

	변수	회귀계수(Coefficient)	p-value	오즈비(Odds Ratio)
6	온라인	0.293410	0.015541	1.340993
2	기수	-0.159632	0.012409	0.852458
1	활동점수	-0.233364	0.000002	0.791866
3	조장여부	-0.527311	0.000234	0.590190

이탈 여부를 종속변수로, 나머지 변수를 독립변수로 설정하여 실행한 로지스틱 회귀 분석 결과이다. 회귀계수와 p-value 를 산출하고, 계수를 지수변환하여 오즈비를 계산하였다. 유의수준은 0.05 로 설정하여 p-value<0.05 인 변수를 통계적으로 유의한 요인으로 판단하였다. 위 사진 속 변수들은 통계적으로 유의한 변수이다. **따라서, [가설 3] [가설 4] [가설 5]를 채택하였다.**

2.5. 이탈 예측 성능 평가

이탈 위험군을 조기에 식별하기 위한 예측 성능을 확인하기 위해 XGBoost 기반 분류 모델을 학습하였으며, 데이터에 맞춘 최적 임계값(threshold=0.264)을 적용하여 평가하였다. 평가 결과 ROC-AUC 는 0.7177 로 유의미한 성능을 보였다.

```
=== [데이터 맞춤형 최적의 Threshold (0.293) 적용] ===
XGBoost 앙상블로 이탈자를 집중 분석했습니다.
              precision    recall  f1-score   support

          유지       0.90      0.88      0.89       592
          이탈       0.37      0.44      0.40        98

    accuracy                           0.81       690
   macro avg       0.64      0.66      0.65       690
weighted avg       0.83      0.81      0.82       690

Confusion Matrix (최적 기준):
[진짜 유지(TN): 519, 가짜 이탈경고(FP): 73]
[놓친 이탈자(FN): 55, 찾아낸 이탈자(TP): 43]

ROC-AUC Score: 0.7061
```

분류 성능은 위의 사진과 같다. 본 결과는 임계값을 0.5 로 고정하지 않고 조정함으로써, 이탈을 더 많이 포착(recall 확보)하도록 기준을 설정하였다. 재현율을 높이는 과정에서 FP 가 증가할 수 있으므로, 운영 목적에 따라 임계값을 조정하는 방식이 필요해 보인다.

3. 결과 해석 및 아이디어 제시

3.1. 로지스틱 회귀 기반 인사이트

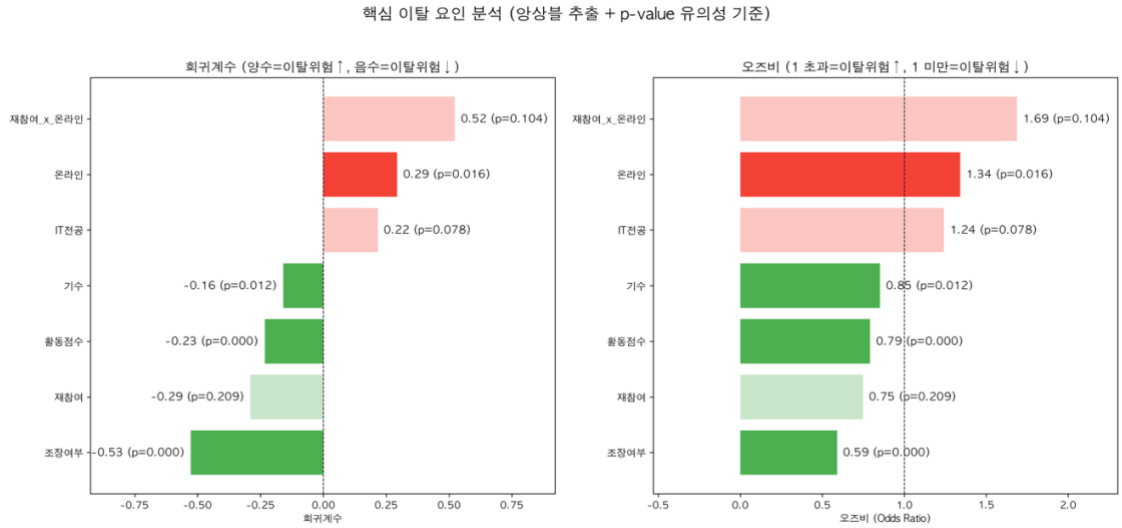

로지스틱 회귀 결과, 유의수준 0.05 기준 통계적으로 유의한 변수를 확인하였다. (2.4.2) 오즈비 기준으로 **온라인은 이탈 위험을 증가시키는 위험 요인(OR 1.34)**이며, 조장여부(OR 0.59), 활동점수(OR 0.79), 기수(OR 0.85)는 이탈 위험을 감소시키는 방어 요인으로 해석된다. 반면, 재참여, 재참여 x 온라인, IT 전공은 **통계적으로 유의하지 않아** 본 분석에서는 보조 변수로 해석하였다.

3.2. 군집분석 기반 학회원 유형 정의

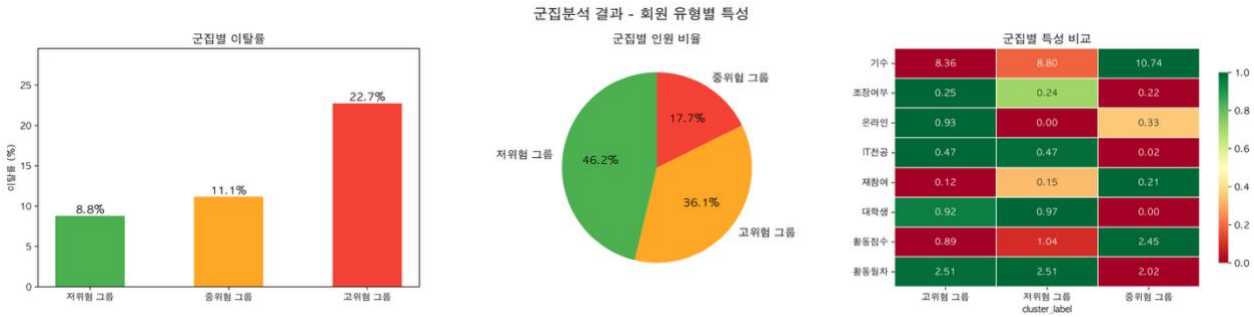

KMeans 군집분석을 통해 학회원을 저위험/중위험/고위험 3 개 그룹으로 유형화하였으며, 군집별 이탈률은 8.8%/11.1%/22.7% 차이가 확인되었다. 군집 특성 비교 결과, **고위험 군집은 온라인 비중이 높고, 활동점수 등 성과 지표가 낮은 방향의 특성을 보인다.** 저위험 군집은 오프라인 비중이 높고 활동 성과가 상대적으로 높은 방향의 특성을 보였다.

3.3. 분석 결과 기반 조별활동 개선안 아이디어 제시

본 절에서는 오즈비 해석(요인 단위)과 군집분석(유형 단위) 결과를 결합하여 운영 적용 가능한 개선안을 제시한다.

1. **위험군 분산 조편성 규칙**

   조편성 시 이탈 위험 요인을 가진 학회원의 비중이 특정 조에 집중되지 않도록 분산 배치한다.

2. **역할 기반 참여 유도**

   조장여부가 이탈 방어 요인으로 확인된 만큼, 조장에게 업무가 집중되지 않도록 한다. 조 내 역할을 세분화해 분담하거나 주차별로 조장 역할을 순환하여 배정한다. 역할과 기여 기준을 명확히 설정하면 참여 책임이 분산되고 활동 지속성이 강화될 것으로 기대된다.

3. **온라인 참여자 전용 운영 장치**

   온라인 참여는 이탈 위험 증가 방향이므로, 온라인 조에는 특별 운영 장치를 추가한다. 예를 들어, 주간 목표 및 산출물 템플릿을 제공하고, 주 1 회 고정 비대면 회의를 운영한다. 또한, 조 내에 응답 지연을 줄이기 위해 질문방과 사담 카톡방을 분리하여 온라인 환경에서 발생하는 진행 불확실성을 낮춘다.

3.4. 사후 운영 전략

1. **위험도 기반 모니터링 및 단계적 개입**

   로지스틱 회귀 예측 또는 군집분석을 통해 고위험군을 정기적으로 선별하고, 운영 개입을 단계화한다. (예를 들어, 리마인드-> 개인 안내 -> 조 재정렬/멘토 투입)

2. **초기 1 개월 집중 케어**

   이탈 시점 분포가 중간 휴회기간 전/후로 가장 많은 것을 볼 수 있다.

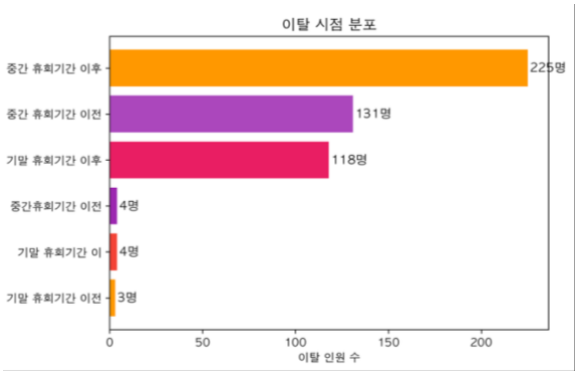

이탈 방지는 초기 습관 형성이 핵심이므로, 휴회기간 전/후를 이탈 방지 집중 구간으로 지정하고, 해당 구간에 점수 가중치 또는 보상(추가 점수, 우수조 가산 등)을 강화한다. 동시에, 휴회기간 이후 복귀가 어려운 참여자를 위해 복귀용 최소 과제 또는 보상을 제공해 다시 돌아오도록 유도한다.

4. 참고 문헌 출처 등

4.1. 데이터 출처

BDA 학회 제공 내부 데이터: member.csv, group_study.csv, group_point.csv

4.2. 사용도구 및 라이브러리

Python (Pandas, NumPy, Matplotlib, Seaborn, statsmodels, scikit-learn, XGBoost)